

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

DIPLOMSKI RAD br. 000

**Obrada i analiza govora na
ugradbenom računalnom sustavu
u stvarnom vremenu**

Paula Franić

Zagreb, svibanj 2019.

*Umjesto ove stranice umetnite izvornik Vašeg rada.
Da bi ste uklonili ovu stranicu obrišite naredbu \izvornik.*

SADRŽAJ

Popis slika	vi
1. Uvod	1
2. Analiza govora	2
2.1. Nastanak glasa	2
2.2. Karakteristike glasa	3
2.2.1. Visina glasa	3
2.2.2. Intenzitet	4
2.2.3. Boja glasa	4
2.2.4. Formanti	4
3. Analiza sluha	6
4. Ugradbeni računalni sustav za obradu govora	8
4.1. DSP Procesor	8
4.2. Vanjske komponente	9
4.2.1. Analogno-digitalni pretvornik	9
4.2.2. MEMS mikrofoni	9
5. Napredna obrada digitalnog signala	10
5.1. Višepojasno filtriranje	10
5.1.1. Filtarske banke	10
6. Algoritam višepojasnog filtriranja	11
7. Analiza performansi sustava	12
8. Zaključak	13

POPIS SLIKA

2.1. Anatomija ljudskog vokalnog trakta	3
2.2. Raspon frekvencija	5
3.1. Anatomija uha	6
3.2. Fletcher-Munson krivulje	7
4.1. Dijagram izvođenja SIMD instrukcije zbrajanja	9

1. Uvod

Digitalna obrada signala (DSP) svoj početak zabilježila je razvojem prvih digitalnih računala 60-ih i 70-ih godina prošlog stoljeća. Naravno, takva računala su bila izrazito skupa tako da se i primjena obrade signala koristila isključivo u vojne svrhe, medicini te razvoju radara i sonara, točnije u svrhe koje su ovisile o velikim financijskim ulaganjima.

Napretkom razvoja digitalnih računala, DSP je svoje uporište našao u razvoju komercijalnih proizvoda kakve danas poznajemo. Tako smo danas upoznati s digitalnim uređajima za obradu zvuka, slike, videa i slično.

Prije daljnje rasprave o digitalnoj obradi signala, razjasnit će se zašto se ona smatra posebnim područjem u inženjerstvu jest što obrađuje jedinstvenu vrstu podataka: signale. Signali su podatak koji najčešće dolazi iz prirode. Tako se njihovom obradom pokušava manipulirati kako bi se postigli ciljevi poput: poboljšanja kvalitete slike, kvalitete zvuka, videa, izdvajanje određenih značajki signala za potrebe raspoznavanja te kompresija.

U ovom radu fokusirat ćemo se na digitalnu obradu zvuka, točnije govora. Zvuk je longitudinalni val koji se vibracijama širi po prostoru, organ koji ga percipira jest uho.

Tako ćemo kroz rad proći osnovni dio vezan uz anatomiju uha kako bismo mogli razjasniti koncept uređaja koji akvizira zvuk te ga obrađuje, specifikacije potrebnih komponenti za akviziciju i obradu zvuka (mikrofon, A/D pretvornik, mikrokontroler) te će fokus biti na implementaciji digitalne obrade govora na ugradbenom računalnom sustavu u stvarnom vremenu.


2. Analiza govora

2.1. Nastanak glasa

Glas nastaje izbacivanjem zraka iz pluća koji putem grkljana, dolazi do glasnica. Prolaskom zraka kroz glasnice one vibriraju pa na taj način nastaje glas. Nakon prolaska glasa kroz glasnice, ono ulazi u ždrijelo te u usnu i nosnu šupljiu gdje se ton glasa mijenja te oblikuje. U oblikovanju glasova sudjeluje jezik, zubi, usne, nepce i čeljust. Kod oblikovanja nastalog glasa, bitno je poznavati funkciju vokalnog trakta. Vokalni trakt se u širem smislu sastoji od sljedećih osnovnih dijelova:

- prostor između glasnica, glottis
- pharynx ili ždrijelo (veza usta i jednjaka)
- usna šupljina
- jezik
- stražnje (meko) nepce
- srednje nepce
- prednje (tvrdo) nepce
- nadzubno meso
- zubi
- usne
- velum ili resica zatvara usnu šupljinu prema nosnoj
- nosna šupljina koja završava s nosnicama

Vokalni trakt se ponaša kao svojevrsan filter, koji će spektralno obojiti pobudni signal. Slično kao što se geometrijom cijevi kod orgulja određuje ton (visina i spektralni sastav) signala koji se formira, tako će i geometrijski oblik vokalnog trakta određivati koje se spektralne komponente signala pojačavaju, a koje prigušuju.



Slika 2.1: Anatomija ljudskog vokalnog trakta

2.2. Karakteristike glasa

Ljudski glas je jedini koji može istovremeno proizvesti riječ i ton. Osnovne karakteristike glasa su: visina, intenzitet i boja. Dotaknut ćemo se i formanta jer njihovo postojanje uvelike utječe na frekvencijsku karakteristiku vokalnog trakta.

2.2.1. Visina glasa

Visina glasa (ton) je perceptivni fenomen, a ovisi o fundamentalnoj frekvenciji koja je fizikalni parametar. Fundamentalna frekvencija (u daljnjem tekstu F_0) je broj vibracija koje glasnice proizvedu u jednoj sekundi. Što je veći broj vibracija glasnica, viša je vrijednost fundamentalne frekvencije pa i glas doživljavamo višim. Brzina titranja glasnica ovisi o debljini, dužini i napetosti glasnica, te o tlaku zraka koji prolazi između glasnica. Povišenje tlaka zraka dovodi istovremeno do povećanja intenziteta glasa i višeg tona. Na vrijednost F_0 utječu dob, spol, tjelesna konstitucija, socijalno okruženje, emocije, intelektualni status. Prosječna F_0 muškog glasa iznosi oko 120 Hz, a ženskog 225 Hz. Istraživanja F_0 djece još su složenija zbog čimbenika rasta i razvoja pa su podaci nekompletni, no zna se da je F_0 prvog plača vrlo visoka i kreće se između 400 i 600 Hz. Porastom kronološke dobi djeteta F_0 pada. Tako npr. za dječake kronološke dobi 10,5 godina vrijednost F_0 iznosi oko 250 Hz.

2.2.2. Intenzitet

Intenzitet ili jakost glasa percipiramo kao glasnoću, a ovisi o amplitudi titranja glasnice, te o subglotičkom tlaku zraka¹. Što su te vrijednosti više, veća je i jačina glasa. Intenzitet se izražava u decibelima (dB). Intenzitetski raspon od tek čujnog glasa do najglasnijeg koji pojedinac može izvesti iznosi i do 70 dB. Ovu razliku između pisanissima i fortissima, tj. najmanje i najveće razine zvuka nekog izvora, nazivamo dinamikom.

2.2.3. Boja glasa


Boja glasa je karakteristika glasa koja čini glas prepoznatljivim za određenog sugovornika. To je perceptivni fenomen koji svaki glas čini jedinstvenim i neponovljivim. Nastaje kao rezultat rezonancije, tj. obrade, ili možda bolje, dorade zvuka na putu od glasnice do izgovora. Taj put je vokalni trakt, a čine ga rezonantne šupljine, ili kraće, rezonatori. Boja glasa ima stalnu i promjenjivu sastavnicu. Stalna ovisi o nasljednim i stečenim anatomsko-fiziološkim karakteristikama, ali isto tako i o načinu uporabe organa za glasanje na što utječe i kulturno okruženje. Promjenjiva sastavnica boje glasa odnosi se na izražajnu mogućnost govornika. Nadalje, o boji glasa prosuđuje se s biološkog, psihološkog, kulturnog, estetskog i patološkog stajališta što potvrđuje koliko je ova karakteristika glasa složena, a opisi i definicije katkad i vrlo različiti. Sinonim za boju glasa je timbar, a u angloameričkoj literaturi vokalna kvaliteta ili kvaliteta glasa što je, zapravo, i širi pojam. U tom kontekstu, glas se opisuje kao pun, voluminozan, kreštav, dahtav, nazalan, drhtav, napet, šušlav, pucketav, zvonak, taman, promukao i slično (Heđever, 2012).

2.2.4. Formanti

Ono što će nam također utjecati na frekvencijski spektar glasa je duljina vokalnog trakta (prije spomenuti faktor kod nastajanja glasa) te veličina otvora na glotisu i ustima. Tu je bitno upoznati se s formantima. Formanti su intenzitetski naglašeni dijelovi spektra nastali rezoniranjem šupljine izgovorom nekog glasa. Možemo uočiti što je veći odnos presjeka otvora i duljine vokalnog trakta to je formant viši. Obično kod analize glasova primjećujemo tri formanta. Drugi formant je viši u smislu što se suženje pomiče prema ustima te što je veći odnos presjeka i duljine vokalnog trakta.

¹Zračni tlak u plućnim alveolama

Sve ove karakteristike određuju frekvencijski spektar glasa. Znamo da ljudsko uho čuje 20 Hz do 20 kHz. Niže frekvencije nose informacije o govoru, dok visoke frekvencije doprinose jasnoći govora. Vidimo na slici 2.2 podjelu područja na tri glavne cjeline, niske, srednje i visoke frekvencije. Ova informacija je bitna kod spektralne analize glasova.




Slika 2.2: Raspon frekvencija

3. Analiza sluha

Nakon pojašnjenja nastanka te karakteristika govora, potrebno je objasniti rad organa za sluh i slušanje: uho.

Akvizicija zvuka počinje s vanjskim uhom. Kada je zvuk putuje prema vanjsko uhu, zvučni valovi, ili vibracije, putuju niz vanjski slušni kanal i udaraju u opnu (bubnjić). Bubnjić vibrira te se te vibracije zatim prenose na 3 sićušne kosti u srednjem uhu koje se nazivaju košćice (čekić, nakovanj i stremen). Košćice se ponašaju kao pojačalo zvuka. One zatim šalju zvučne valove u unutarnje uho i u slušni organ ispunjen tekućinom (pužnica).



Slika 3.1: Anatomija uha


Kada zvučni valovi dosegnu unutarnje uho, oni se pretvaraju u električne impulse. Slušni živac šalje ove impulse u mozak. Mozak tada prevodi ove električne impulse

kao zvuk.(Ashutosh Kacker, 2019)

Jedna od bitnijih značajki uha jest što je ono, uz osjetilo vida, jedino osjetilo koje jačinu signala percipira po logaritamskoj skali. Znamo također da razlike u jačini snage između najtišeg i najglasnijeg zvuka koje ljudsko uho može percipirati jest 10^6 .

Također, prilikom obrade zvuka, moramo na umu imati da čovjek ima dva uha, tako da vrši akviziciju iz dva smjera te tako može percipirati smjer dolaska zvuka. Ovo nam je također bitno kod obrade kako bi imali dva izlaza koji simuliraju stereo zvuk.

Zanimljiva karakteristika uha jest ovisnost frekventijskog odziva prema glasnoći zvuka, što možemo vidjeti na slici 3.2. Tu možemo uočiti nejednaku osjetljivost uha na niske frekvencije



Slika 3.2: Fletcher-Munson krivulje

Govor spada pod već spomenute zvučne signale. Kao što je u poglavlju 3 objašnjeno, ljudsko uho može percipirati signale frekvencija od 20 Hz do 20000 Hz. Ljudski govor spada u područje od 200 Hz do 5000 Hz, ovisno o spolu i dobi osobe. Iako je tu već očigledno da nam neće biti potreban spektar iznad 5000 Hz, nastojat ćemo ga zadržati nakon očitavanja kako ne bi gubili na kvaliteti signala, što nam je u ove svrhe bitno.

4. Ugradbeni računalni sustav za obradu govora

Uređaj koji želimo razviti za potrebe obrade govornog signala nam zahtjeva ključne komponente:

1. procesor sa DSP značajkama
2. analogno-digitalni pretvornik s performansama prilagođenim za audio signale
3. MEMS mikrofoni koji vrše akviziciju signala

Kod ovakvog sustava potrebno je pobrinuti se da je akvizicija signala brza i ne narušava inicijalnu frekvencijsku karakteristiku glasa te da je obrada signala brza i kvalitetna.

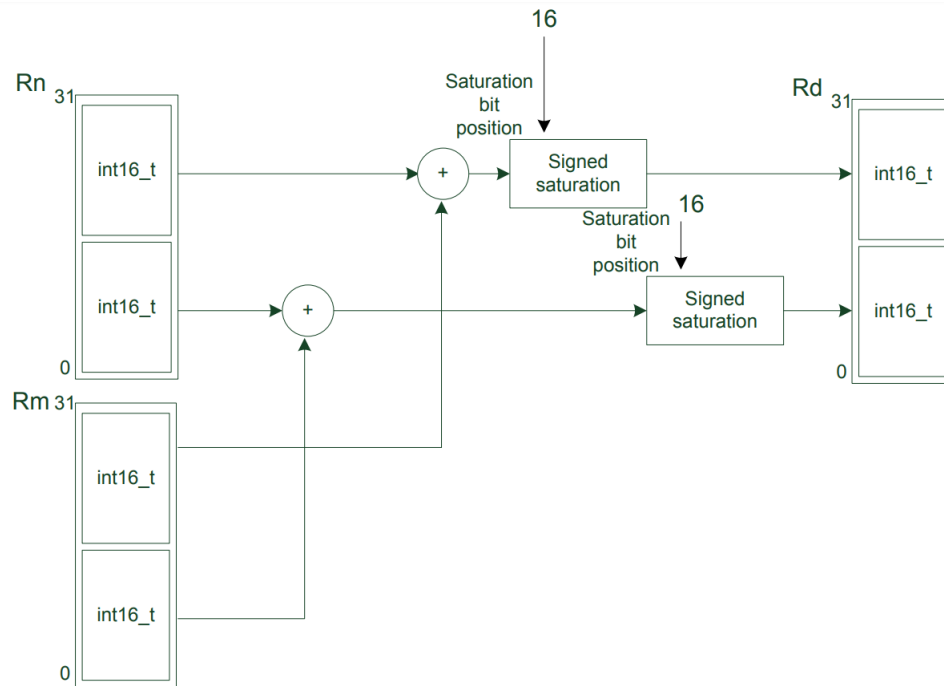
Naš ugradbeni računalni sustav jest STM32F407VG. On sadrži ARM Cortex-M4 procesor sa DSP značajkama koji će nam biti ključan za daljnju obradu signala. Ovaj mikrokontroler već ima ugrađeni MEMS mikrofoni i A/D pretvornik no oni su namijenjeni za opću primjenu, dok su nama potrebne komponente za isključivu obradu audio signala tako da će se u daljnjim potpoglavljima napraviti usporedba dostupnih te traženih komponenti.

4.1. DSP Procesor

Odabrani ugradbeni računalni sustav sadrži ARM-ov procesor Cortex-M4. Ovaj procesor spada u familiju Cortex-M procesora koji se koriste za ovakve svrhe. Glavne karakteristike takvih procesora je visoka efikasnost potrošnje energije, mala površina procesora, kratki cjevovodi te rad na frekvenciji oko 200 MHz (ARM, 2016).

Ono što čini ovaj procesor pogodnim za digitalnu obradu audio signala jest što ima podršku za funkcije tog tipa pomoću SIMD i MAC instrukcija.

Single Instruction Multiple Data (SIMD) je skupina instrukcija koje omogućuju paralelno izvođenje operacije za više podataka.



Slika 4.1: Dijagram izvođenja SIMD instrukcije zbrajanja

Kao što se vidi na slici 4.1, podatke koje želimo zbrojiti podijelimo na nižih 16 bita i viših 16 bita. Kod oba podatka zbrajaju se posebno niži bitovi i posebno viši bitovi. Ono što je ključno kod SIMD naredbe jest aritmetika zasićenja. U slučaju da zbroj nižih ili viših bitova prelazi maksimalni broj koji je moguće spremiti, on se zaokružuje na taj maksimalni broj. SIMD instrukcije zbog ove karakteristike imaju najčešću primjenu u audio sustavima.

Multiply and Accumulate (MAC) je skupina instrukcija fundamentalna za digitalnu obradu signala. Ona omogućuje množenje dvaju podataka te zbrajanje s vrijednosti akumulatora u jednom ciklusu, što je čini savršenom kod filtriranja podataka pomoću FIR filtara.

$$a < -a + x * y$$

4.2. Vanjske komponente

4.2.1. Analogno-digitalni pretvornik

4.2.2. MEMS mikrofoni

5. Napredna obrada digitalnog signala

5.1. Višepojasno filtriranje

5.1.1. Filtarske banke

6. Algoritam višepojasnog filtriranja

7. Analiza performansi sustava

8. Zaključak

Zaključak.

LITERATURA

ARM® Cortex®-M for Beginners. ARM, 2016.

Ronald Karlin Ashutosh Kacker, Daphne Pierce-Smith. *Anatomy and physiology of the ear*. 2019.

Mladen Heđever. *Govorna akustika*. 2012.

Obrada i analiza govora na ugradbenom računalnom sustavu u stvarnom vremenu

Sažetak

Sažetak na hrvatskom jeziku.

Ključne riječi: Ključne riječi, odvojene zarezima.

Title

Abstract

Abstract.

Keywords: Keywords.